共识论文分享：从PBFT到HotStuff

刘克猛　liukemeng2018@163.com

目录

1 同步、异步概念

- **异步**(asynchrony)：系统中各个节点可能存在较大的时钟误差、消息传递时间是任意长的，各节点对消息的处理时间也可能是任意长的。
- **同步**(synchrony)：系统中各个节点的时钟误差存在上限、消息传递在一定时间内完成，各节点完成处理消息的时间是一定的。

2 FLP不可能原理

- 在网络可靠，但是允许节点失效（即使只有一个）的最小化异步模型系统中，不存在一个可以解决一致性问题的确定性共识算法。

3 CAP定理

- 一个分布式系统不可能同时满足一致性（强一致性）、可用性和分区容错性，只能三选二。

  分区容错性是分布式系统基本要求，因此共识算法将在强一致性与可用性，即安全性与活性之间权衡。

4 部分同步假设（PBFT、Tendermint、HotStuff、LibraBFT）

- **部分同步**(partial synchrony)：在一个全局稳定时间（GST）后，会有一段同步的状态。

相关概念

1 N>=3f+1

- 因为有 **f** 个节点可能是拜占庭节点（即不作出响应），因此两次读写请求都需要在 **N-f** 个节点返回响应后完成共识，这两次操作响应的节点交集至少有 **N-2f** 个；
- 上面假设的 **f** 个不作出响应的节点，可能仅仅由于网络延迟，这样的话在交集中可能存在 **f** 个拜占庭节点，为了达成共识需要满足 **N-2f>f**，即 **N>3f**,也即 **N>=3f+1**。

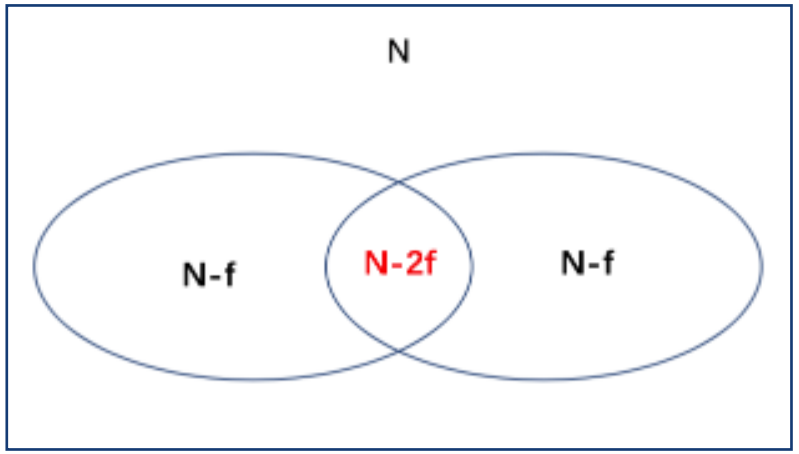

2 Quorum>=2f+1

- 假设quorum的大小为 **Q**，那么：任意两个quorum集合的交集大小至少为 **2Q-N**,交集中至少要有超过 **f** 个节点，因此：**2Q-N >= f + 1**,即：**Q >= (N + f + 1) / 2**，也即 **Q >= 2f+1**（不严谨）。

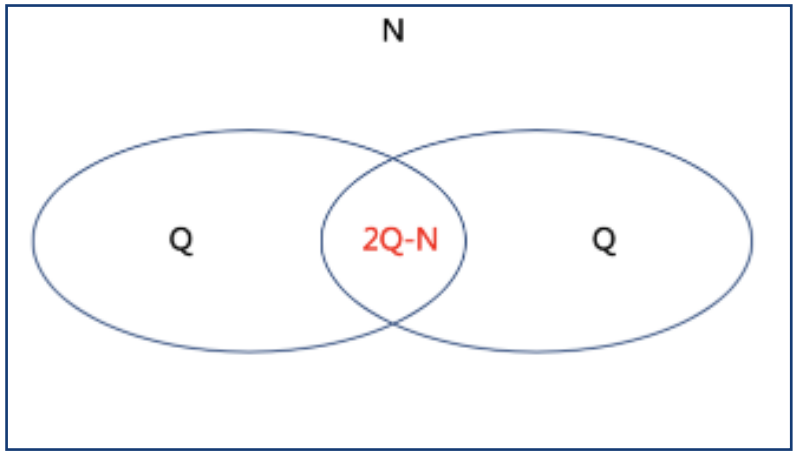

99年

Normal-Case Operation

1. **视图** (View)：将时间分为一段一段连续的view，在一个view中有一个rimary，其他节点是backup；
2. **主节点** (Primary)：决定client请求的操作的执行顺序，并打包发给backups；
3. **副本节点**(Backups)：验证消息的合法性，在收到quorum个消息时，对共识的消息达成一致；

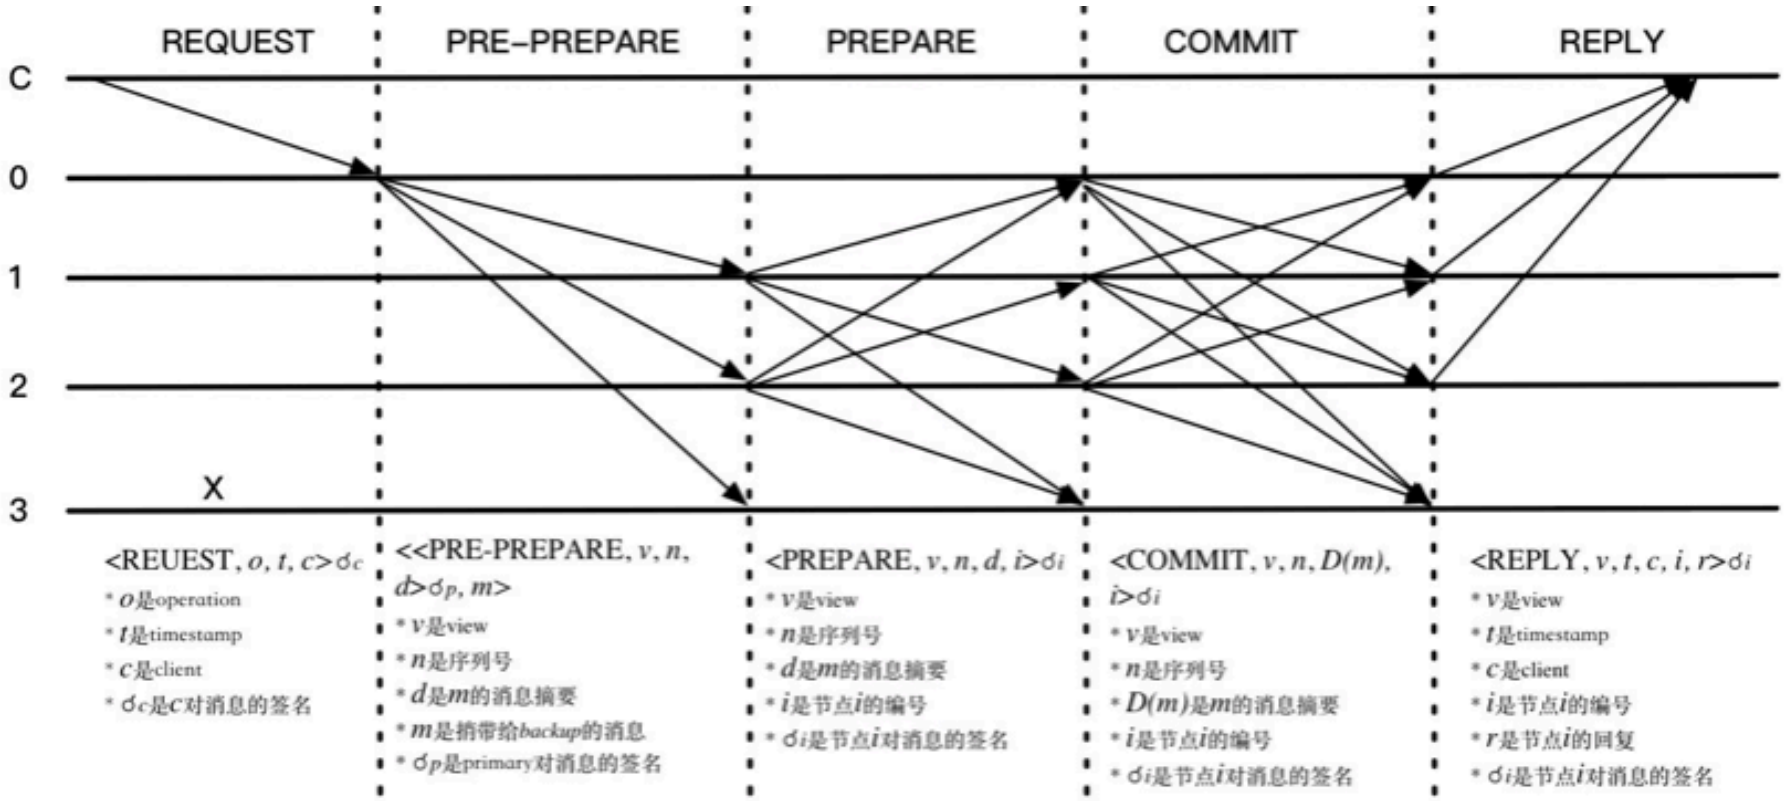

Normal-Case Operation

1. **视图** (View)：将时间分为一段一段连续的view，在一个view中有一个primary，其他节点是backup
2. **主节点** (Primary)：决定client请求的操作的执行顺序，并打包发给backups；
3. **副本节点**(Backups)：验证消息的合法性，在收到quorum个消息时，对共识的消息达成一致；

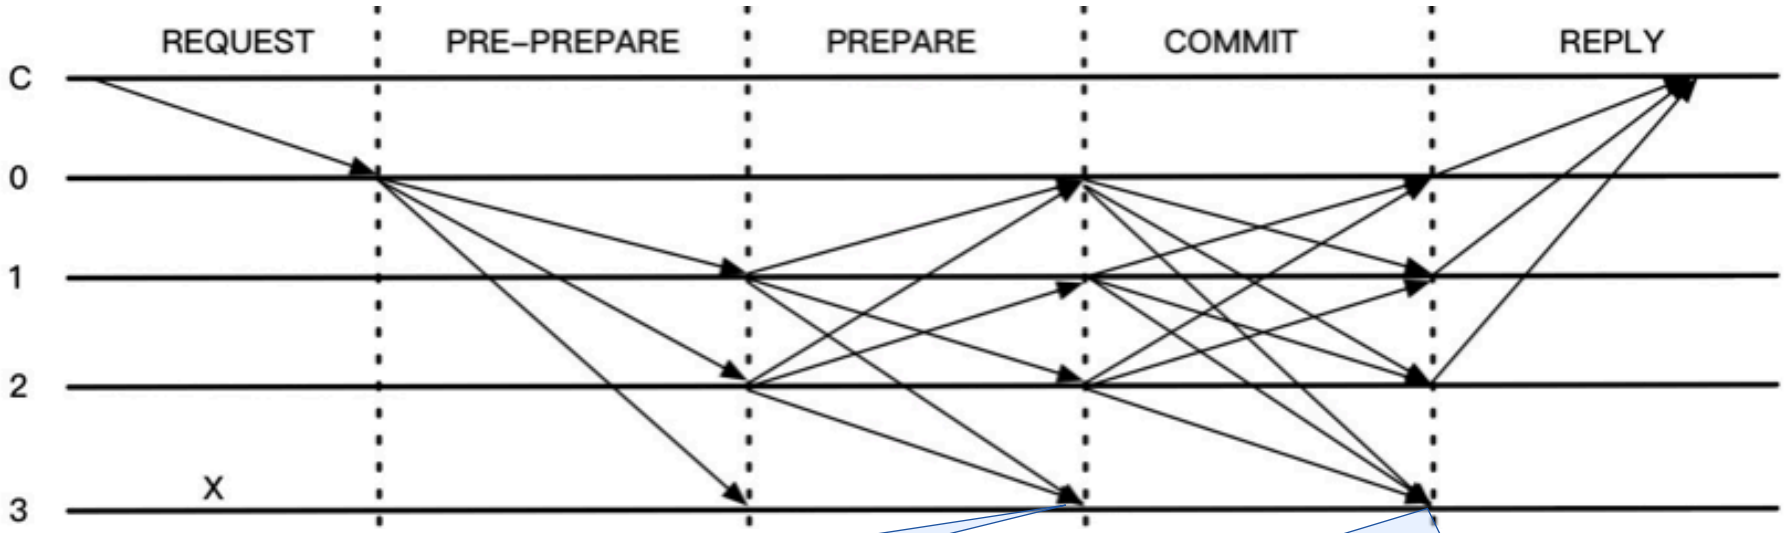

收到**2f**个Prepare消息，
节点达到***Prepared****(m,v,n,**i**)*状态

收到**2f+1**个Commit消息，节点达到
Committed-local*(m,v,n,**i**)*状态，
requestBatch达到***Committed****(m,v,n)*状态，此时至少有**f+1**个诚实的节点到达了***Prepared***状态

Garbage Collection

1. PBFT将定时（每执行K个requestBatch）产生checkpoint记录当前链状态，并向其他节点组播 <CHECKPOINT,n,d,i>σ_i，**n** 是“最近”被执行的requestBatch的编号，**d** 是这个batch执行后对应的状态的哈希；
2. 当节点收集到 **2f+1** checkpoint，并且序号n和d是不冲突的，这个n被认为是**稳定检查点**。此时，节点会丢弃所有小于等于n的log entries和更早的checkpoints。
3. 然后，会更新自己low、high water marks：
    - h = n；
    - H = h + L（L = K * m，m为常数）

作用：

1. 清除共识过程中产生的已经过期的log entries，减少存储；
2. 在checkpoint过程中，可以及时发现自己落后了，可以执行stateUpdate；
3. 在viewchange过程中，作为下一个视图共识从哪个序号继续进行的依据；

View Changes

1. **View-change阶段**：当主节点超时没有产生PrePrepare消息，或者在Prepare阶段验证主节点产生的PrePrepare消息不合法或者冲突，或者在Prepare、Commit阶段没在规定时间内收到 **2f / 2f+1** 个一致合法的消息，则发送<VIEW-CHANGE,v+1,n,C,P,i>σ_i 消息，其中 **n** 是节点i的最新稳定检查点，**C** 是 **2f+1** 个有效checkpoint消息，**P**是序号大于n的到达***Prepared***状态的消息集合， $\mathbf{P_m}$由关于m的**1**个PrePrepare消息和**2f+1**个prepared消息组成。

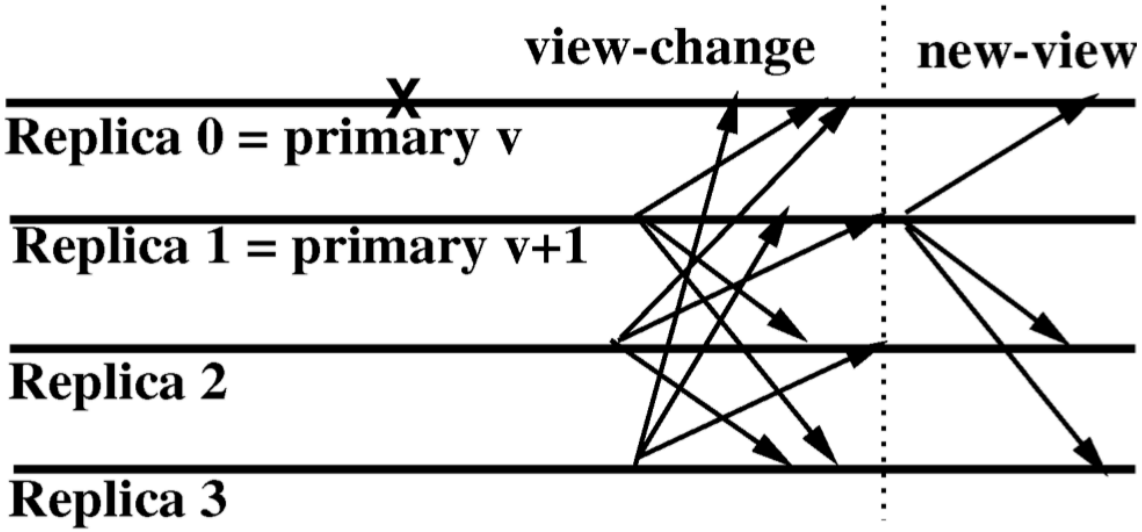

View Changes

2. **New-view阶段**：当view+1所对应的New primary收到了**2f**个有效的view-change消息，它就会广播<NEW-VIEW, v+1, V, O>消息，其中**V**是它收到的**2f**个view-change消息，证明new-view的正确性，**O**是新生成的 pre-prepare消息的集合，新的主节点按照如下过程计算O：
   - 根据收到的view-change，计算最近的稳定检查点 **min-s** 和最高的prepared块的序号作为**max-s；**
   - 对介于 min-s 和max-s 之间的每个序号n创建新的**pre-prepare**消息

     如果P中存在一个$\mathbf{P_m}$序号为n，那么**<PRE-PREPARE, v+1, n, d>** σ_i

     如果不存在，那么就放一个空块，**<PRE-PREPARE, v+1, n, $\mathbf{d^{null}}$>** σ_i

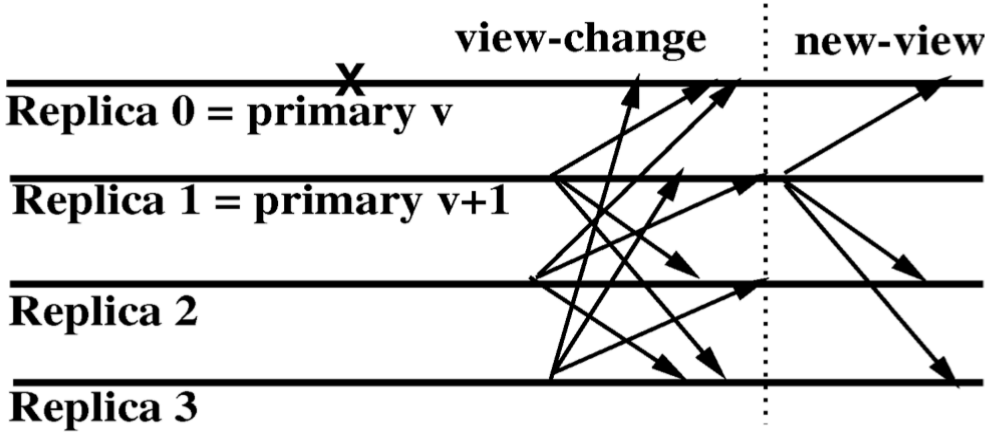

Safety and Liveness

1 Safety: 所有诚实的节点对于到达committed的消息的序号达成一致

- 在一个视图内，不会有两个requestBatch（序号都是n）都到达***Prepared***状态；
- 在不同的视图间，通过视图转换 <VIEW-CHANGE,v+1,n,C,P,i>σ_i，把到达*Prepared*状态的requestBatch“显式”地传到下一个视图，这样保障所有“可能”到达committed状态的requestBatch在诚实的节点间序号是一致的；

2 Liveness: 不能对一个requestBatch达成共识，需要进入到下一个视图（还需要保证至少2f+1个诚实节点有足够的时间进入到这个视图）

- 视图转换也保障了活性；
- 为了避免视图转换太频繁，保障所有的诚实节点都有足够的时间转换到下一个视图。每一次视图切换设置一个定时器，并且下一次视图转换定时器时间为上次的double；
- 为了避免视图转换太慢了，收到f+1个有效的view-change，节点就会发送view-change ；

优缺点总结

1 优势:

- 首个实用的BFT容错算法，使得复杂度从指数级降到多项式级 $O(n^2)$；
- 响应性（Responsiveness）：在网络状况OK，主节点不犯错，拜占庭节点数量不超过f个时，在下一个视图一定是可以达成共识的；

2 不足:

- 通信复杂度 $O(n^2)$ ，可扩展性低；
- 视图转换的复杂度 $O(n^3)$，要是连续视图转换复杂度 $O(f* n^3)$，视图转换复杂，很“重” ；
- 视图转换期间只能接收viewchange、newview消息不能对外提供服务；
- Safety和Liveness耦合，都需要通过视图转换来保障；
- 去重机制没有提；

Fabric 0.6PBFT源码分析： https://github.com/Liukemeng/Fabric0.6-PBFT-Learning

Consensus Process

1. **轮次**(Round)：类似但不同于View，Round是基于某一height高度的块的，新的块Round会置为0；
2. **提案者** (Proposer)：打包出块节点，同PBFT中的Primary；
3. **验证者**(Validators)：所有的共识节点都是验证者，同PBFT中的Replicas；

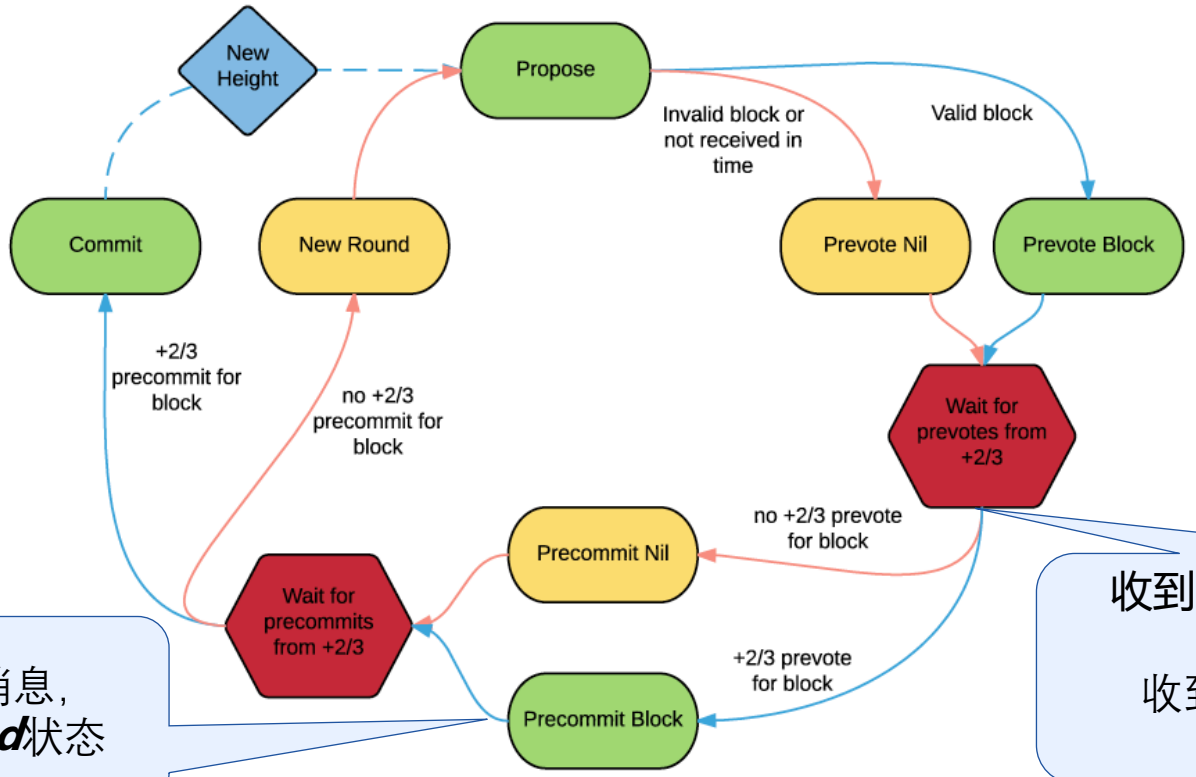

节点发送了precommit消息，
节点到达***pre-committed***状态

收到+**2/3**个Prevote for block消息，
区块达到***polka***状态
收到+**2/3**个Prevote for nil消息，
达到***nil-polka***状态

Safety and Liveness

1 Prevote-the-Lock:

- 验证者在之后的round中只会给Prevote给它锁定的那个块；
- 如果成为提案者，他会propose它锁定的那个块 ；

2 Unlock-on-Polka:

- 当验证者收到一个round比自己所处的轮次大，并且到达polka状态的块时，接收这个块作为这个高度的块，并释放之前锁定的那个块；

优缺点总结

1 优势:

- 用锁的机制代替了PBFT中复杂的viewChange，但是丧失了响应性；
- 工程化成功，可直接基于其开源的框架搭建一条链；
- 联盟链和公有链均可用；

2 不足:

- 丧失响应性：没有“显式”地将polka状态的proposals传到下一个round；
- Safety和Liveness耦合：加锁、解锁机制耦合在一起；

Model

1. **视图**(View)：同PBFT中的View，严格递增；
2. **主节点** (Leader)：打包定序、出块节点，同PBFT中的Primary；
3. **从节点**(Replicas)：接收、验证主节点发送过来的消息，并发送投票消息，同PBFT中的Backups；

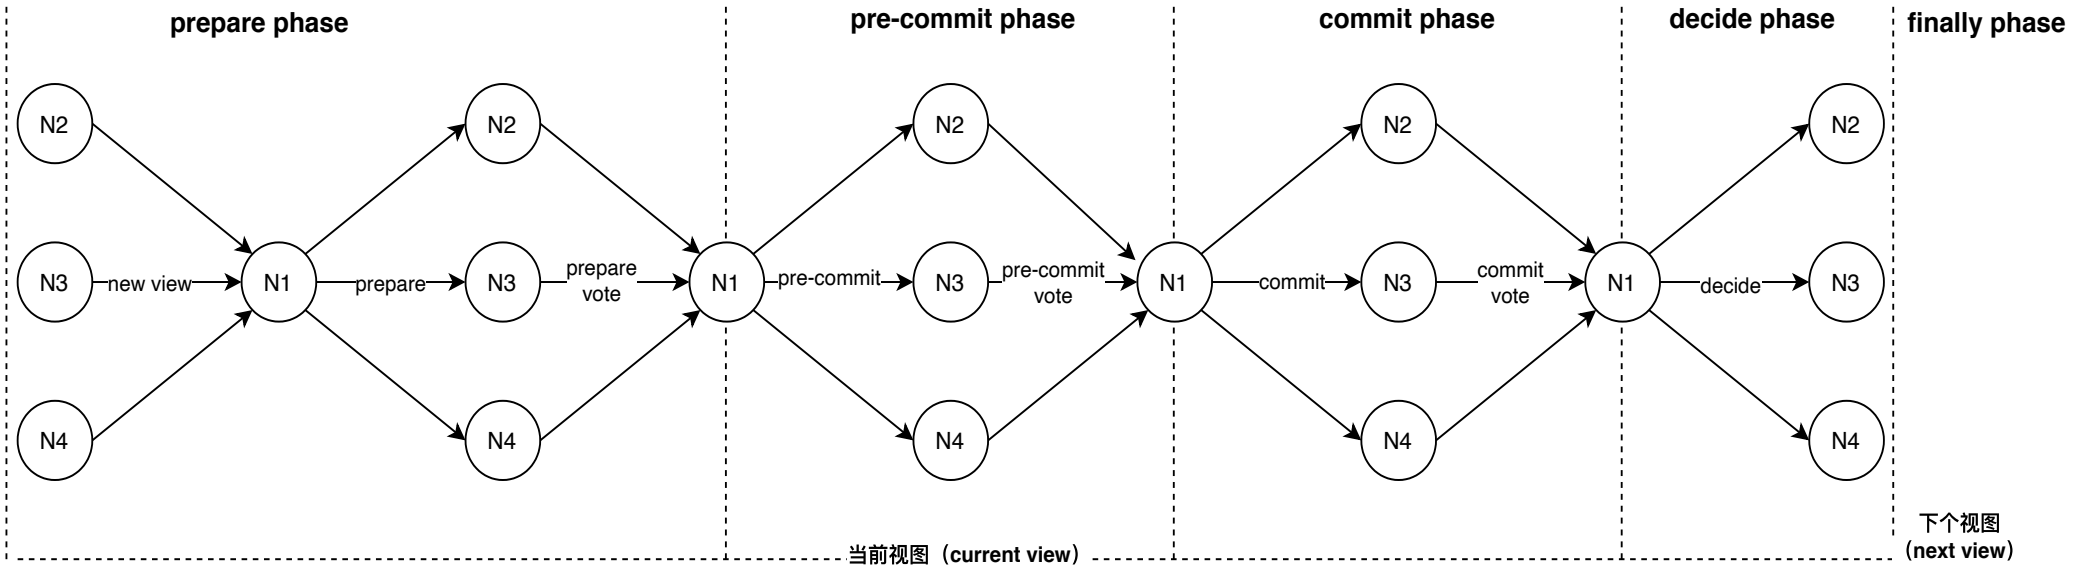

Basic HotStuff

1. Basic HotStuff整个过程包括5个阶段：准备阶段（PREPARE）、预提交阶段（PRE-COMMIT）、提交阶段（COMMIT）、决定阶段（DECIDE）和最终阶段（FINALLY）。
2. 所有共识消息通过**签名**来证实其有效性，使得每一轮交互**只需要主节点**进行广播，然后收集n-f个节点对同一个块提案的投票消息，利用门限签名将其合成一个QC，网络复杂度降低至**O(n)**线性复杂度。

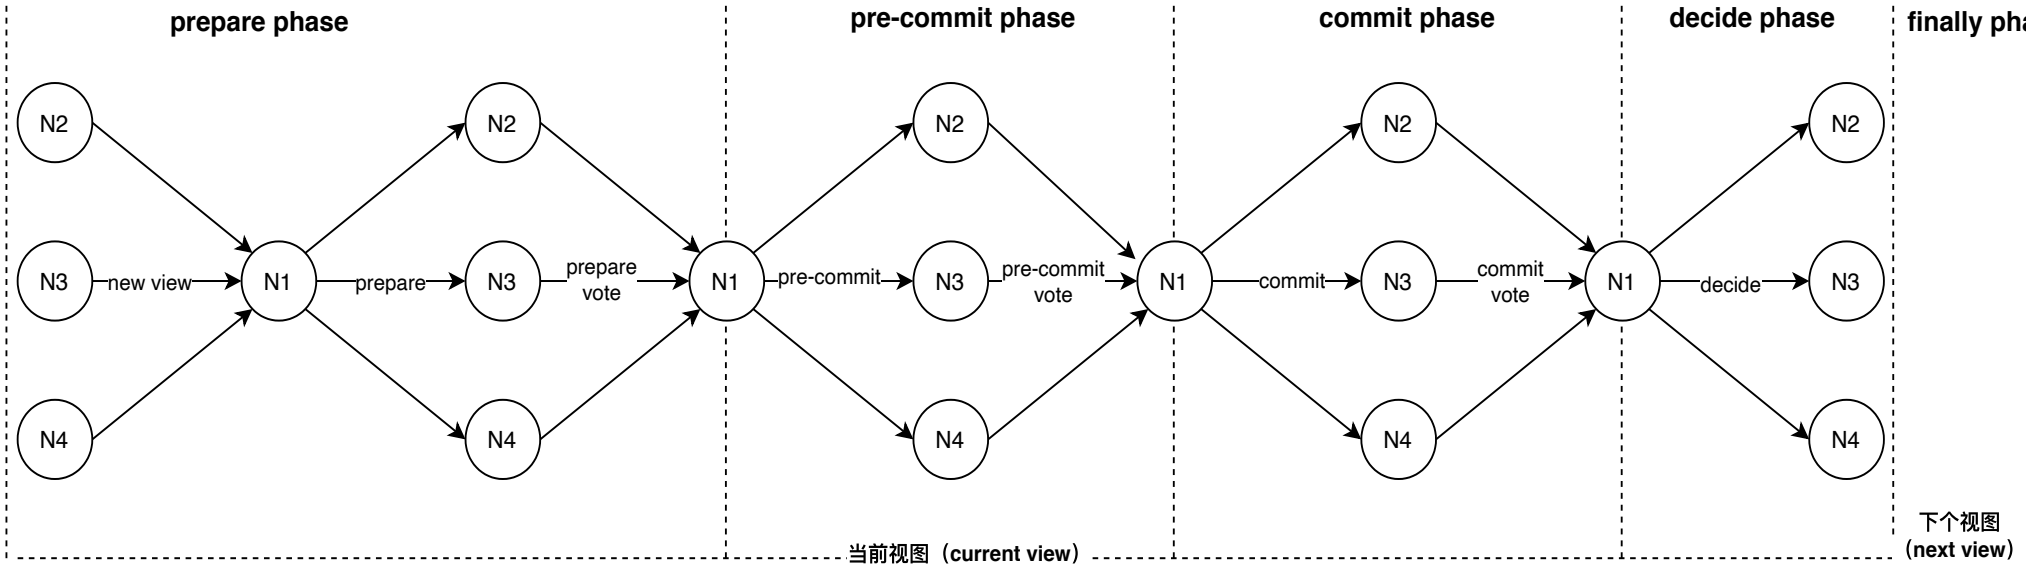

QC (quorum certificate，证书)：主节点收到n-f个节点对同一个区块提案的投票消息（带节点签名）后，利用门限签名将其合成一个QC证书。

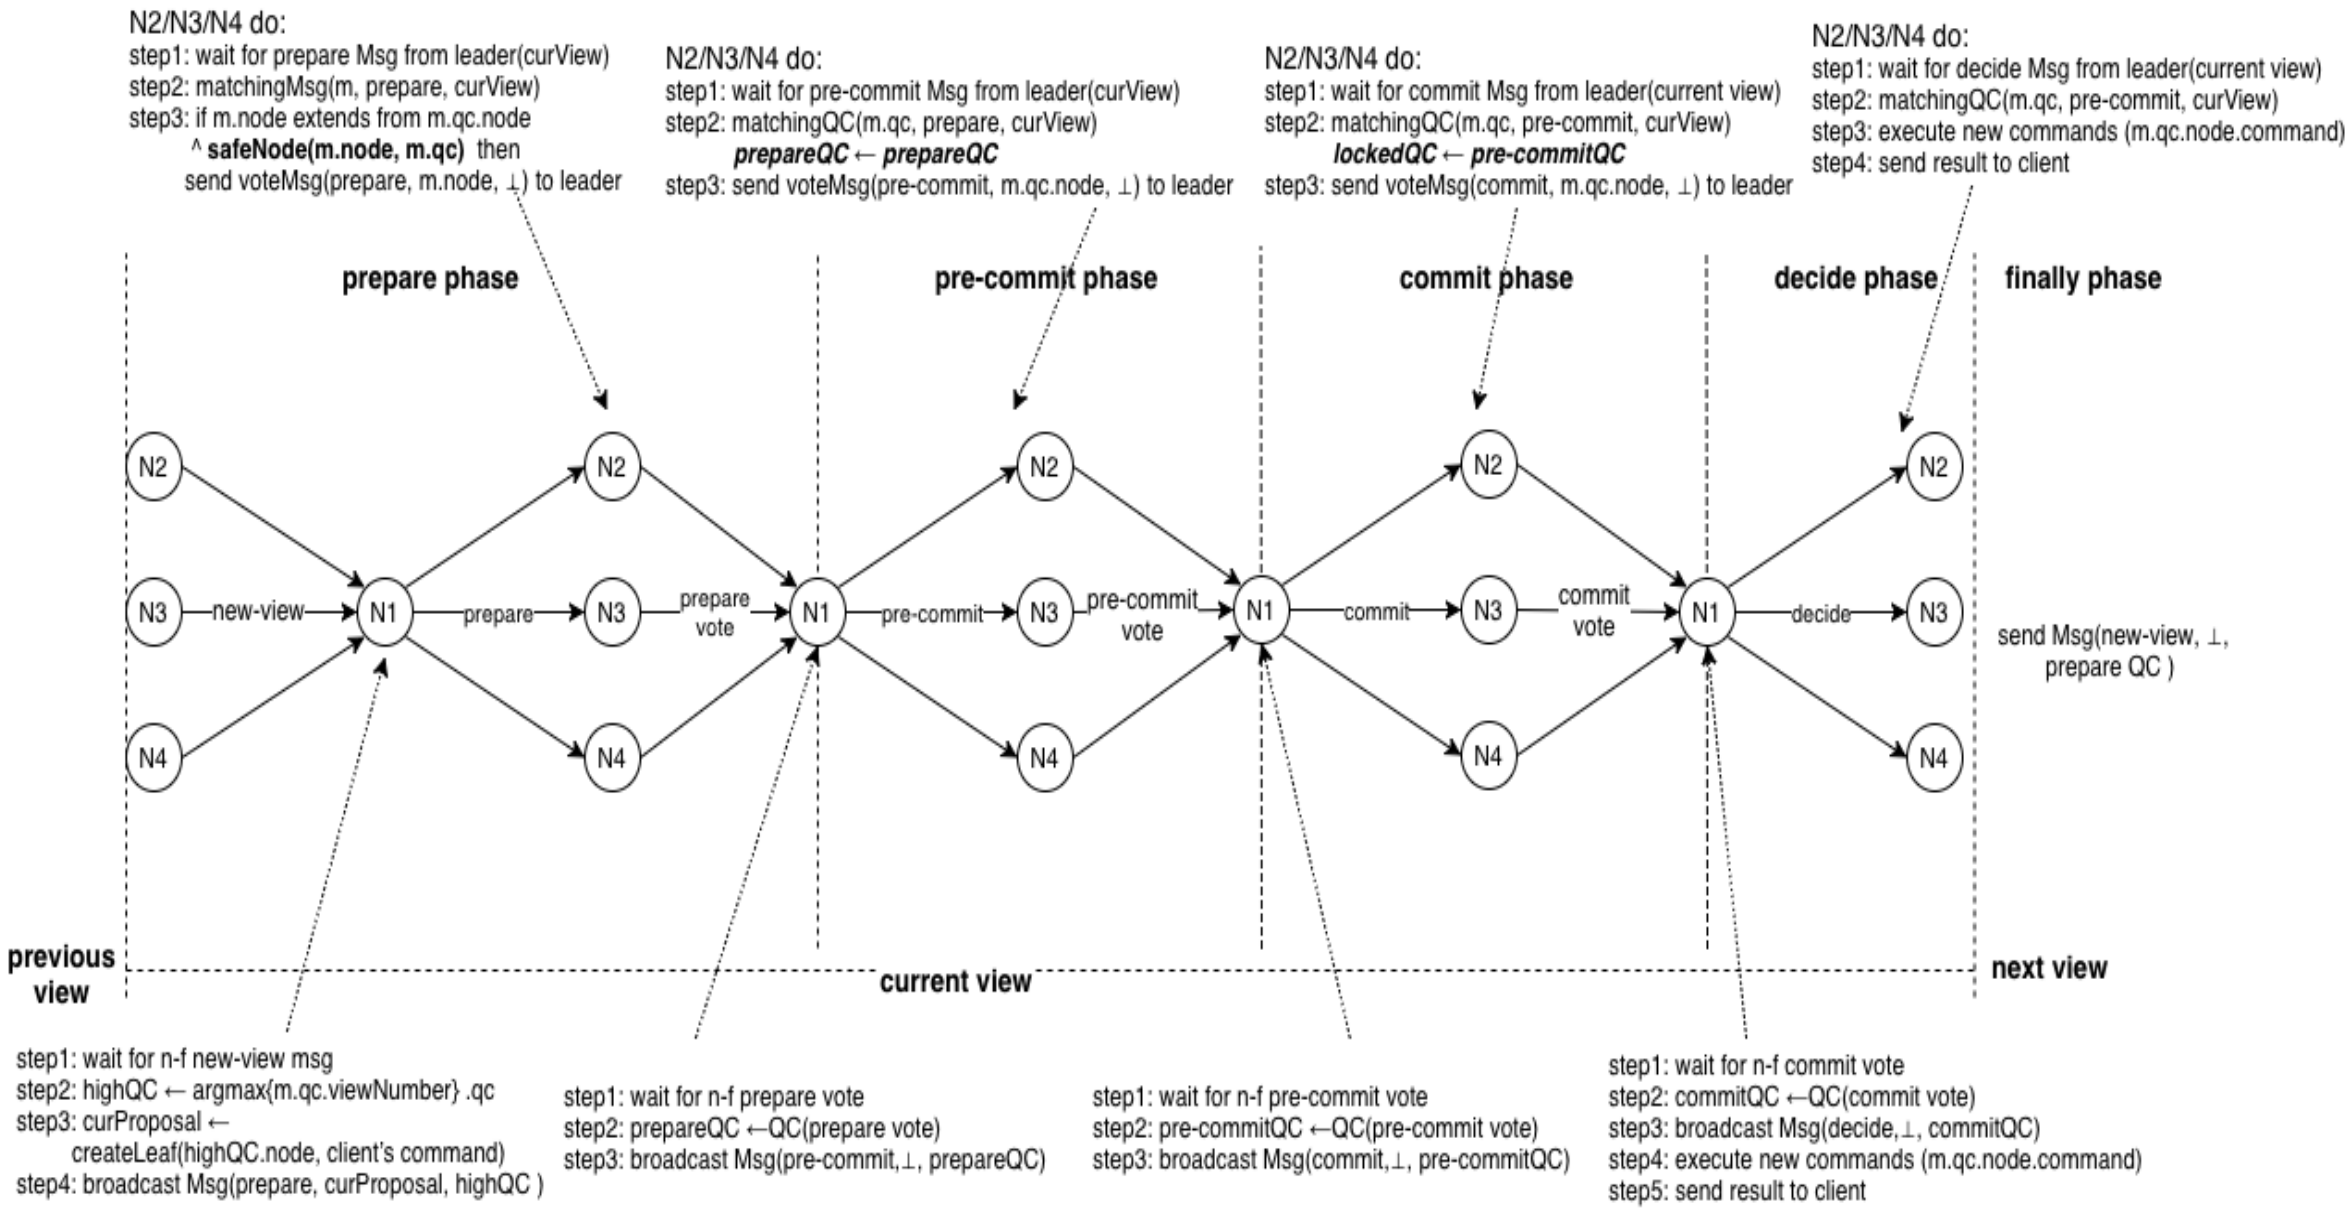
N2/N3/N4 do:
step1: wait for prepare Msg from leader(curView)
step2: matchingMsg(m, prepare, curView)
step3: if m.node extends from m.qc.node
^ safeNode(m.node, m.qc) then
send voteMsg(prepare, m.node, ⊥) to leader
N2/N3/N4 do:
step1: wait for pre-commit Msg from leader(curView)
step2: matchingQC(m.qc, prepare, curView)
prepareQC ← prepareQC
step3: send voteMsg(pre-commit, m.qc.node, ⊥) to leader
N2/N3/N4 do:
step1: wait for commit Msg from leader(current view)
step2: matchingQC(m.qc, pre-commit, curView)
lockedQC ← pre-commitQC
step3: send voteMsg(commit, m.qc.node, ⊥) to leader
N2/N3/N4 do:
step1: wait for decide Msg from leader(current view)
step2: matchingQC(m.qc, pre-commit, curView)
step3: execute new commands (m.qc.node.command)
step4: send result to client
prepare phase
pre-commit phase
commit phase
decide phase
finally phase
N2
N3
N4
N1
new-view
prepare
prepare vote
pre-commit
pre-commit vote
commit
commit vote
decide
send Msg(new-view, ⊥, prepare QC)
previous view
current view
next view
step1: wait for n-f new-view msg
step2: highQC ← argmax{m.qc.viewNumber} .qc
step3: curProposal ← createLeaf(highQC.node, client's command)
step4: broadcast Msg(prepare, curProposal, highQC)
step1: wait for n-f prepare vote
step2: prepareQC ←QC(prepare vote)
step3: broadcast Msg(pre-commit,⊥, prepareQC)
step1: wait for n-f pre-commit vote
step2: pre-commitQC ←QC(pre-commit vote)
step3: broadcast Msg(commit,⊥, pre-commitQC)
step1: wait for n-f commit vote
step2: commitQC ←QC(commit vote)
step3: broadcast Msg(decide,⊥, commitQC)
step4: execute new commands (m.qc.node.command)
step5: send result to client

SafeNode predicate

1. **Safety Rule**：Proposal消息中的区块**m.block**是从本节点***lockedQC***的区块扩展产生;
2. **Liveness Rule**：当Proposal的highQC(**m.justify**)高于本节点***lockedQC***中的viewnumber时也会接收该proposal；

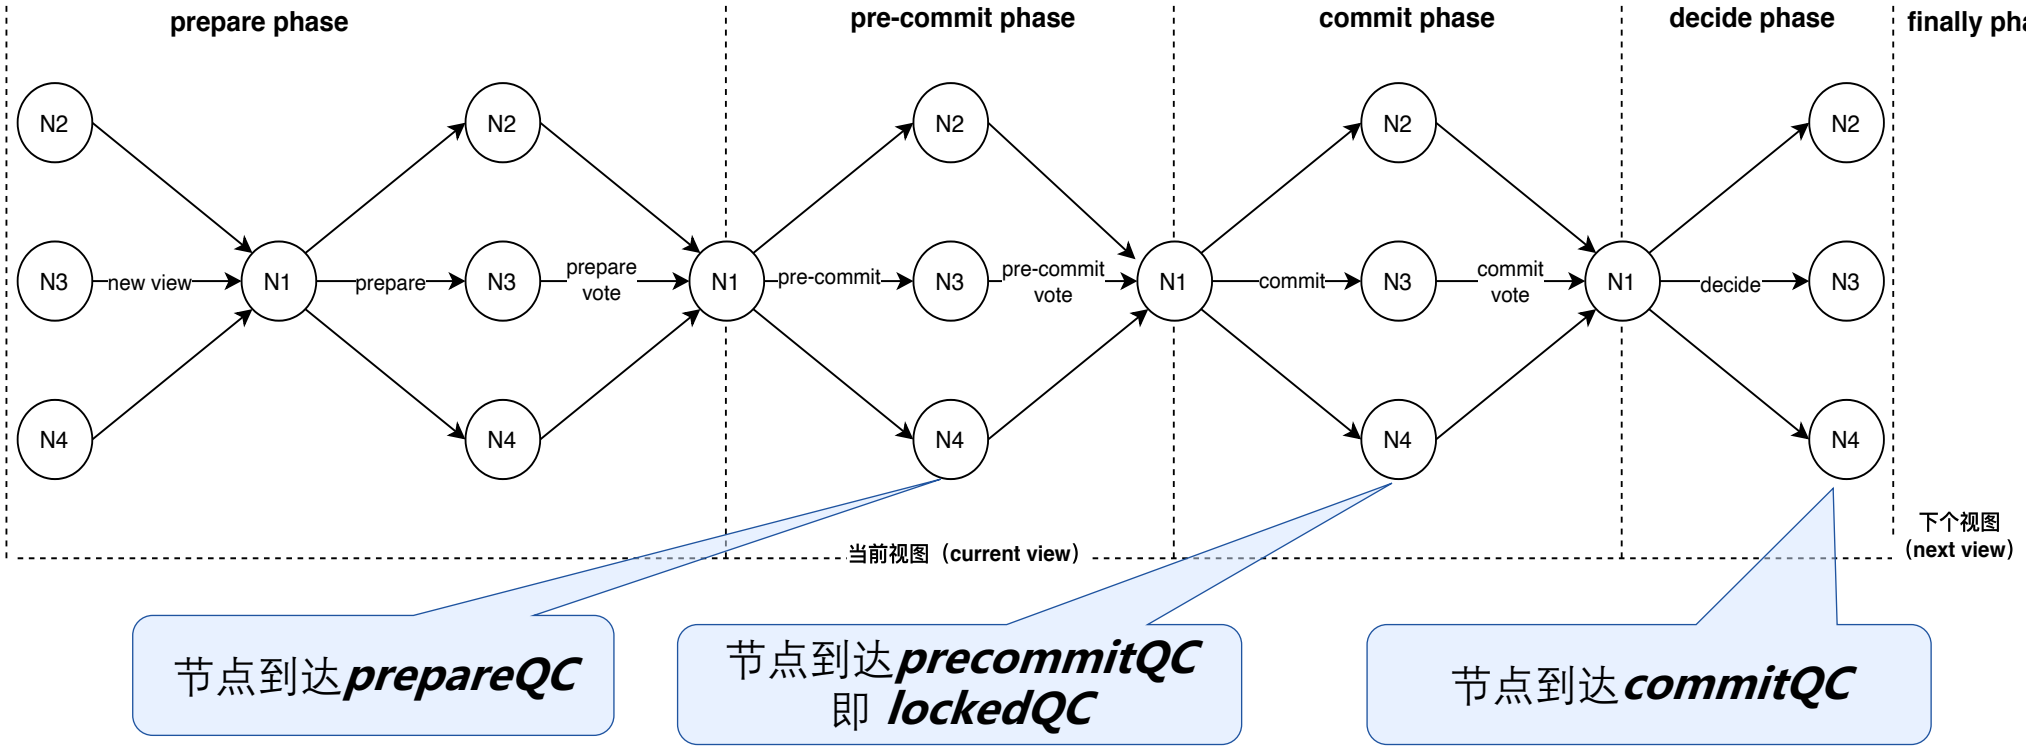

Safety and Liveness

1 Safety:

- **同一个View下，不会对冲突的区块，产生相同类型的QC；**

  这样的话至少有一个诚实节点给两个冲突的块都投票了；

- **正常Replica不会对两个冲突的区块到达committed；**

  同一个视图下，正常的replica不会对冲突的区块产生commitQC，所以不会commit冲突的区块。

  在不同的视图下，假设viewNumber在v1和v2时（v1 < v2），commit了冲突的区块，即存在commitQC_1 = {block1, v1}, commitQC_2={block2, v2}，且block1与block2冲突。在v1和v2之间,肯定存在一个最小的v_s(v1 < v_s <= v2)，使得v_s下存在有效的prepareQC_s{block_s, v_s},其中block_s与block1冲突。当含有block_s的prepare被广播后，节点会对该消息做safety验证。

  由于block_s与block1冲突，所以显然，不符合safety规则1；

  假如block_s.parent.viewNumber > block_1.viewNumber，那么显然block_s.parent与block_1冲突，所以block_s.parent是更早的与block1冲突的，这与v_s最小矛盾。

Safety and Liveness

2 Liveness :

- 有一个节点对这个块到了lockedQC，那么就有f+1个诚实的节点对这个块到达了prepareQC，这样就会至少有一个诚实的节点把这个prepareQC状态的块传到下一个视图。就可以基于这个prepareQC作为highQC构造新的块。
- 并且如果在GST之后，主节点是诚实节点，拜占庭节点小于f个，那么一定会达成共识，满足optimistical responsensive。

Chained HotStuff

Basic HotStuff各个阶段的流程高度相似，HotStuff作者便提出Chained HotStuff来简化Basic HotStuff的消息类型，并允许Basic HotStuff的各阶段进行流水线（pipelining）处理。

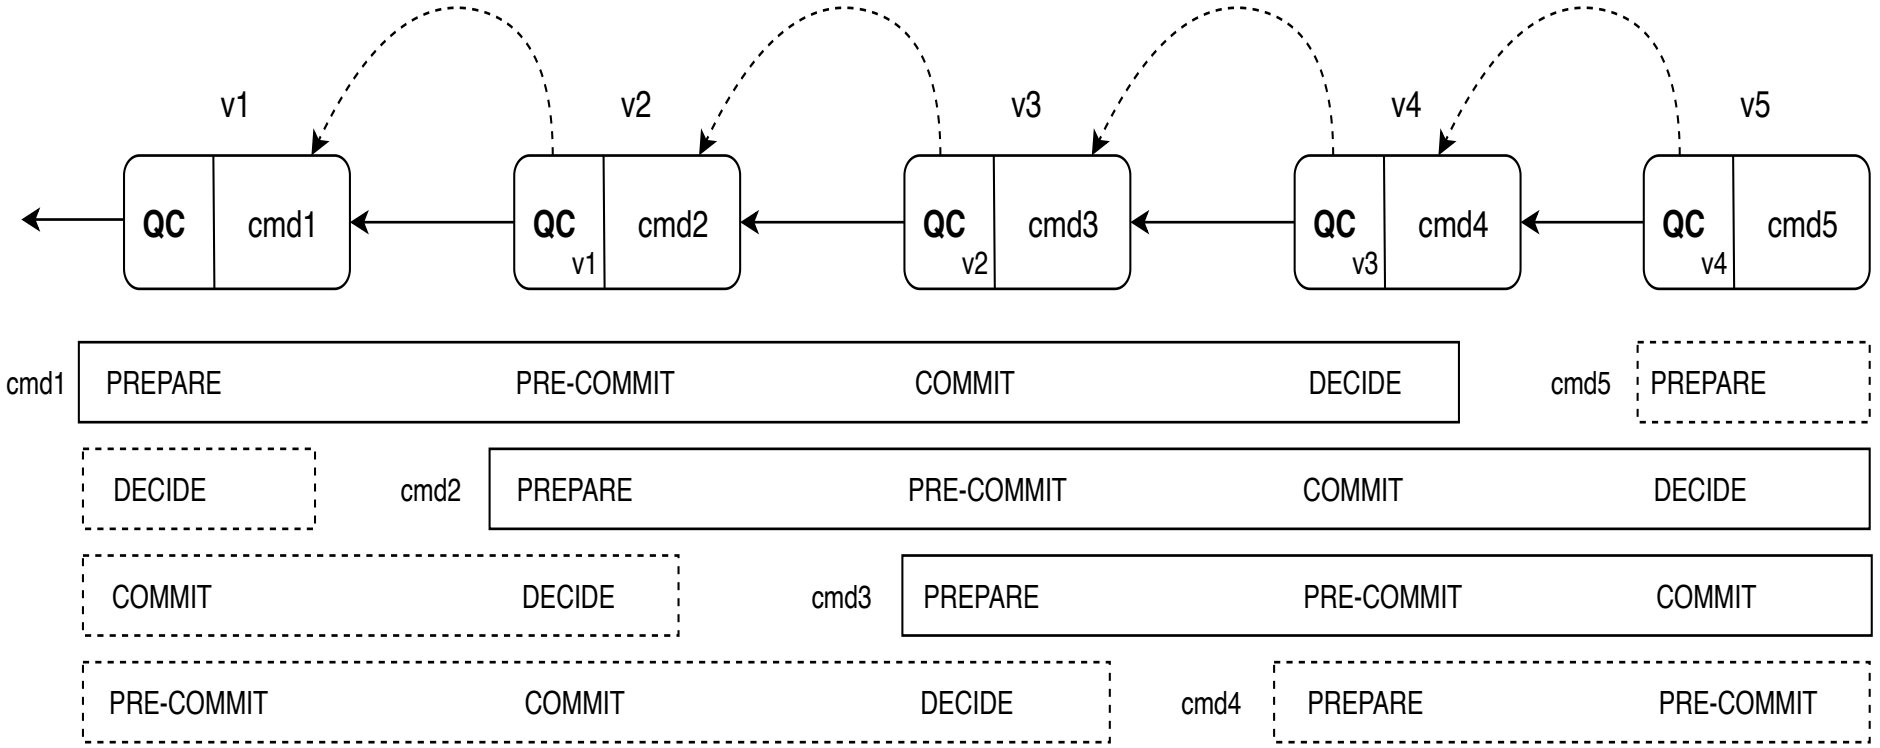

优缺点总结

1 优势:

- 采用门限签名将通信复杂度从$O(n^2)$降低为$O(n)$；
- 线性视图转换，把轮换主节点融入了常规共识流程中，切换主节点无需增加其他协议和代价，且系统在此期间还能继续对外提供服务，并且兼具响应性；
- 将安全性和活性解耦，活性组件Pacemaker作为一个工作模块独立于共识协议的安全条件，这极大地降低了HotStuff定制活性机制的难度，无需修改协议本身的内容便可获取更多的活性保障；

2 不足:

- 活性机制灵活性不够：只有一个全局超时时间，没有为共识流程中的每个步骤设置完善的超时机制；
- 没有提到去重机制；

相关概念

1. **轮次**(Round)：同HotStuff中的流水线形式下的轮次投票，严格递增；
2. **主节点** (Leader)：打包定序、出块节点，同HotStufff中的Leader；
3. **验证者**(Validator)：接收、验证主节点发送过来的消息，并发送投票消息，同HotStuff中的Replicas；

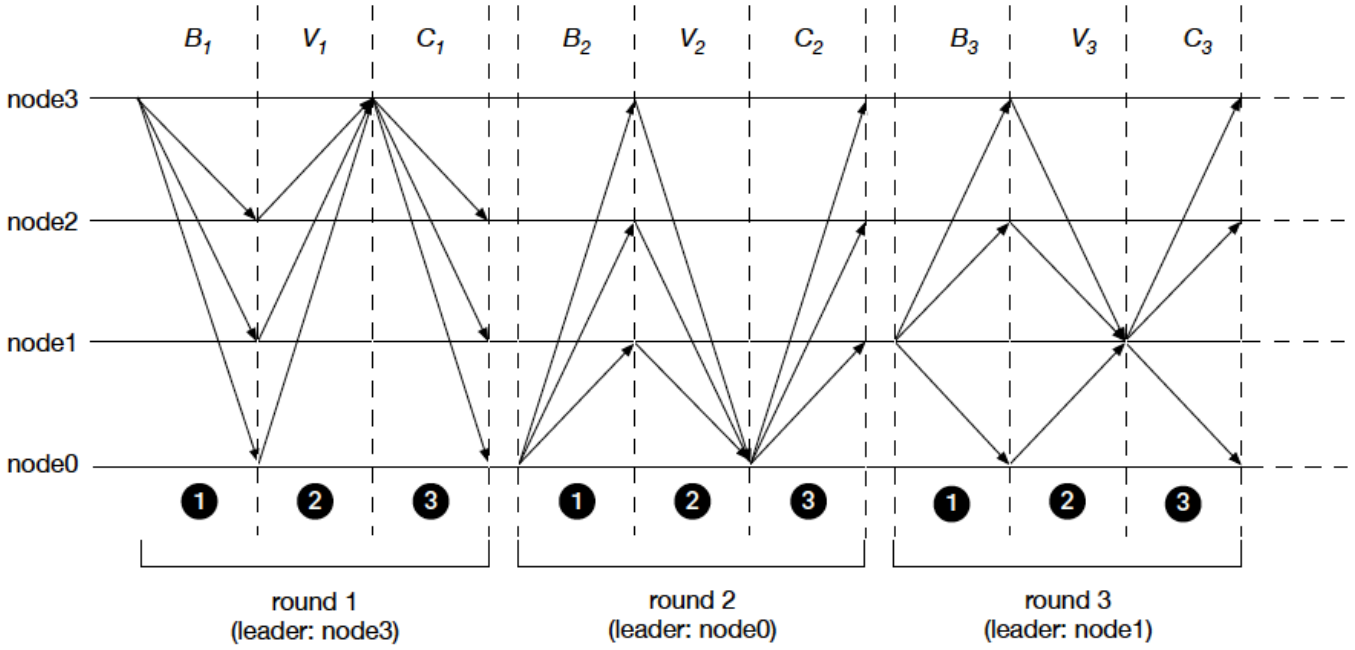

主流程

共识模块主要负责交易的定序与执行结果的一致性校验，通过3-chain达成提交条件：

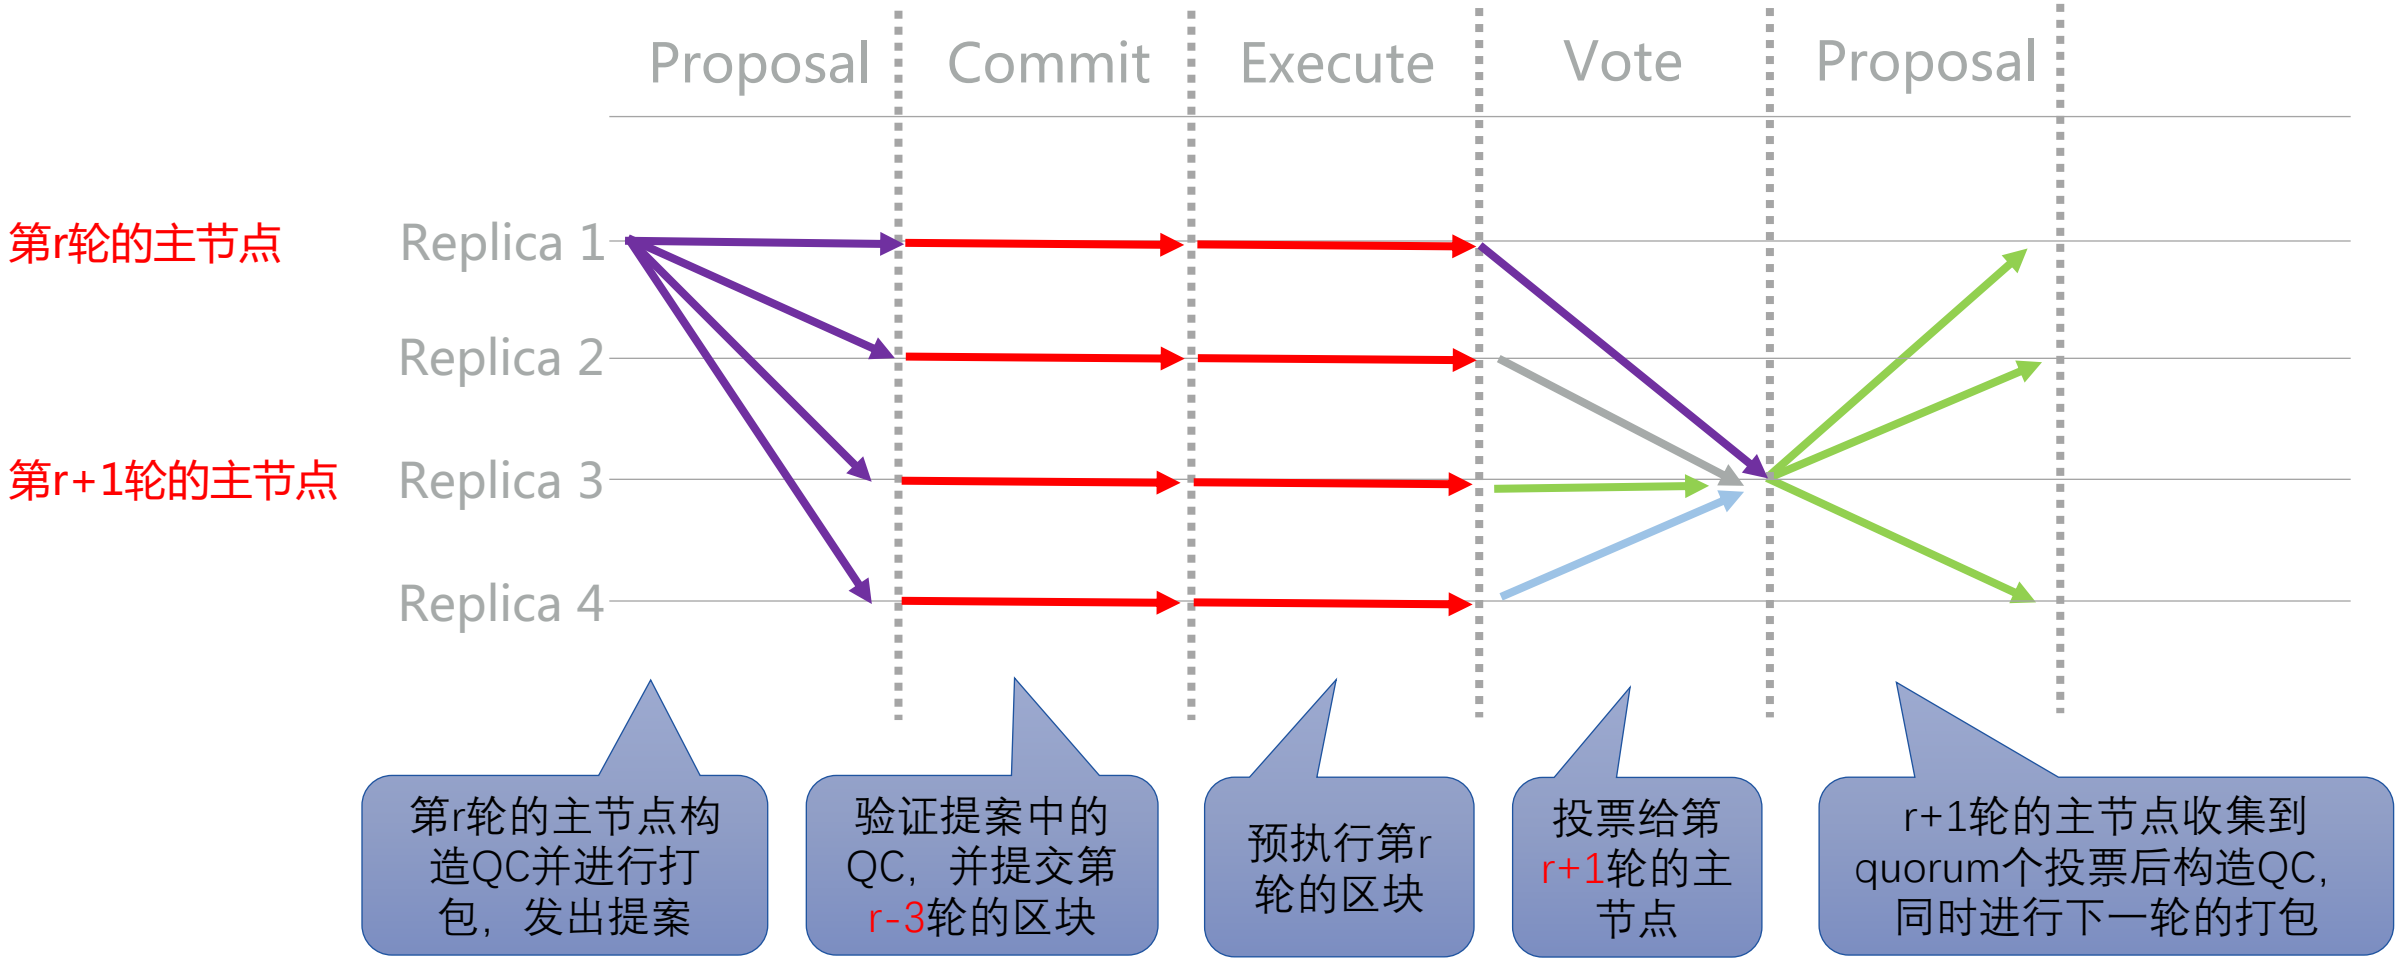

超时处理

超时之后，可能引发”分叉”

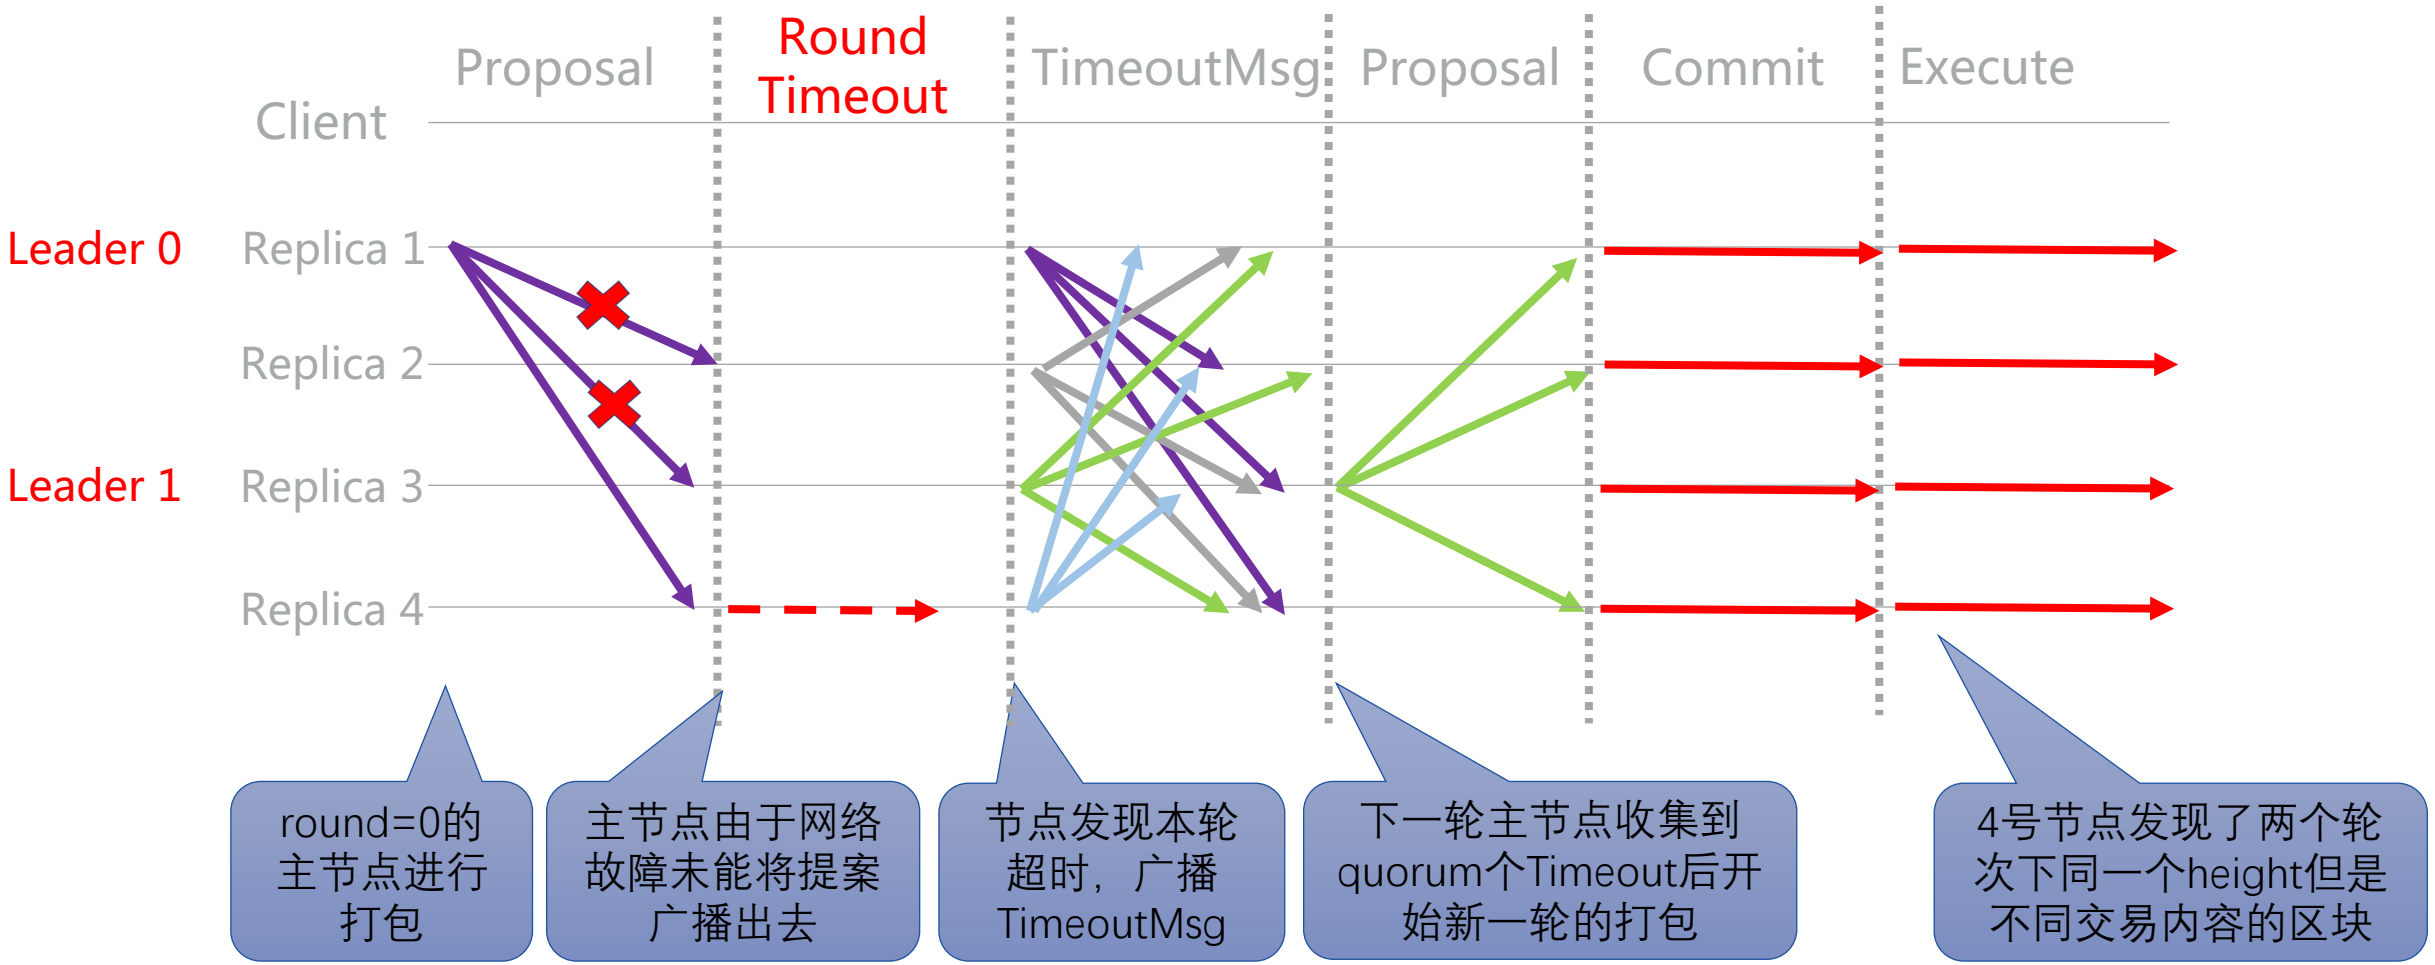

超时处理

预执行可能会引起“分叉”，即相同block height下可能存在多个不同的block在不同的round下执行，这些不同block下的状态通过3-chain来判断提交。

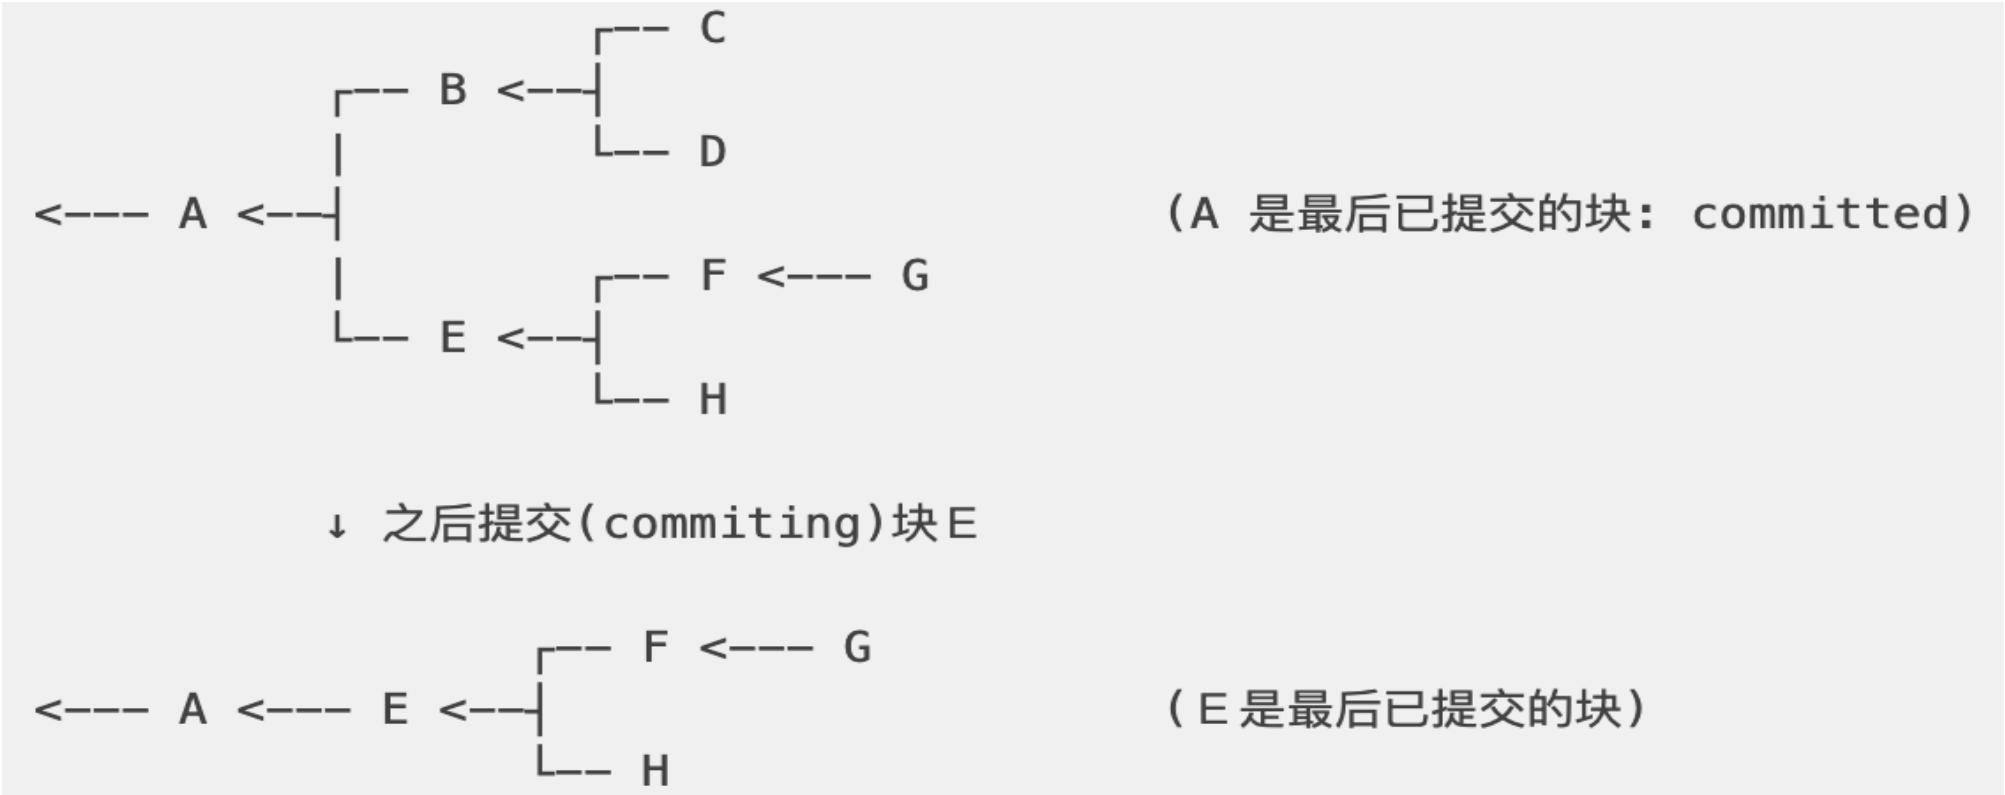

优缺点总结

1 优势:

- 共识的是区块的状态，及执行的结果，而不仅仅是交易的顺序，增强了鲁棒性，也可以允许客户端使用QC验证从数据库里读出的数据；
- 扩展了HotStuff的Pacemaker，通过Pacemaker来发出明确的超时信号，验证者通过它发出的消息自动进入到下一个视图，而不需要一个同步时钟；
- Leader的选举变得不可预测，以最新提交的区块信息作为种子生成一个可验证的随机函数来判断自己是否成为下一个节点；
- 采用了交易缓冲池来进行交易去重，

2 不足:

- 去重机制简单，只有新提交交易的序列号比该账户最新提交的交易的序列号大一位，Libra才会将这笔交易加入共识提案中，造成同一账户下的交易之间产生了依赖性；
- 采用了Ed25519签名算法，但是没有实现聚合；

算法对比

Protocol	Authenticator complexity *Correct leader*	*Leader failure (view-change)*	*f leader failures*	Responsiveness
DLS [25]	$O(n^4)$	$O(n^4)$	$O(n^4)$	
PBFT [20]	$O(n^2)$	$O(n^3)$	$O(fn^3)$	✓
SBFT [30]	$O(n)$	$O(n^2)$	$O(fn^2)$	✓
Tendermint [15] / Casper [17]	$O(n^2)$	$O(n^2)$	$O(fn^2)$	
Tendermint* / Casper*	$O(n)$	$O(n)$	$O(fn)$	
HotStuff	$\boldsymbol{O(n)}$	$\boldsymbol{O(n)}$	$\boldsymbol{O(fn)}$	✓

谢谢大家！